

Indice

1	Introduzione	1
2	Exploit	5
2.1	ELF, loading	5
2.1.1	Program header table	6
2.1.2	Global Offset Table e Procedure Linkage Table	8
2.2	Return oriented programming	11
2.2.1	Gadget	12
2.2.2	Address Space Layout Randomization	14
2.2.3	Return-to-plt, GOT dereferencing e GOT patching	15
3	Architettura di Dropper	17
3.1	Modulo dropper	18
3.2	Modulo gadgetstools	22
3.2.1	Emulazione e catalogazione	23
3.2.2	Verifica e validazione	23
3.2.3	Verifica degli effetti secondari	24
3.3	Payload Chunk	25
4	Implementazione di Dropper	26
4.1	Dropper	26
4.1.1	Interazione con l'utente	26
4.1.2	Analisi degli import	27
4.1.3	Costruzione della catena	27
4.2	GadgetsTools	29
4.2.1	Selezione dei gadget per l'impostazione dei registri	29
4.2.2	Selezione dei gadget per la scrittura in memoria	30

4.2.3 Selezione dei gadget per la operazioni aritmetiche in memoria	31
4.3 PayloadChunks	33
4.4 Utilizzo di pianificatori per la costruzione della catena	34
5 Conclusioni	39
5.1 Sviluppi futuri	41

Capitolo 1

Introduzione

A seguito dell'introduzione di misure di sicurezza come l'isolamento delle pagine di memoria, la casualizzazione dello spazio degli indirizzi, e il controllo della consistenza dello stack le tecniche per poter sfruttare gli errori presenti in un programma al fine di ottenerne il controllo sono cambiate radicalmente.

La tecnica forse più abusata era lo *stack smashing* [12], con la quale si compromisero centinaia di sistemi. La tecnica consisteva nello sfruttare un errato controllo dei limiti di un buffer memorizzato sullo stack per poter corrompere lo stack stesso, errore identificato come *stack buffer overflow*. In questo modo poteva essere “iniettato” nello stack codice arbitrario, solitamente definito *shellcode* per via del suo obiettivo più comune: ottenere una shell.

Nello stack sono presenti informazioni chiave per il funzionamento del programma. Ad esempio, al momento di una chiamata a funzione, l'indirizzo dell'istruzione successiva viene memorizzato sullo stack, in questo modo, una volta terminato il lavoro della funzione, il programma sa da dove riprendere l'esecuzione. L'attaccante, una volta preso il controllo dello stack, può sovrascrivere il valore dell'indirizzo di ritorno, controllando da dove il programma continuerà. L'attaccante quindi può, compromettendo lo stack, redirezionare il flusso del programma in modo che esegua il codice da lui stesso iniettato.

Sono state introdotte diverse misure di protezione per mitigare questo tipo di attacco. Con l'introduzione dell'isolamento delle pagine di memoria è stato possibile adottare una politica dei permessi in memoria con granularità una singola pagina. Il tentativo di eseguire delle istruzioni presenti in una pagina non eseguibile, così come il tentativo di scrivere su una pagina non scrivibile causa l'arresto del programma. Il codice legittimo viene mappato

in memoria in pagine eseguibili ma non scrivibili, mentre stack e dati che il programma deve manipolare vengono mappati su pagine scrivibili ma non eseguibili. In questo modo non si può più semplicemente iniettare del codice, in quanto le aree di memoria scrivibili (tra cui l'area di memoria riservata allo stack) non potranno essere eseguite. Un'altra misura di protezione per rendere più difficile questo tipo di attacco è la casualizzazione dell'indirizzo di memoria nel quale risiede lo stack. In questo modo, non sapendo dove il codice iniettato effettivamente risiede, non si sa dove dover redirezionare il controllo del flusso per eseguire il codice iniettato.

Tuttavia l'isolamento delle pagine di memoria e la casualizzazione dello stack non evita la compromissione né del flusso del programma né dello schema dello stack. Una delle tecniche utilizzata per ottenere il controllo di un programma nonostante lo stack non sia marcato come eseguibile si chiama *return-to-libc*[5]. In un utilizzo tipico di questa tecnica il flusso del programma non viene dirottato su un payload iniettato dall'attaccante ma su una funzione di una qualche libreria utilizzata dal programma. Su un architettura a 32bit gli argomenti vengono passati alle funzioni posizionandoli secondo un ordine preciso (definito dalla *calling convention*) sullo stack. Dato che anche lo schema dello stack può essere compromesso l'attaccante ha di fatto il controllo degli argomenti da passare alla funzione. Potendo, ad esempio, richiamare la funzione `system` della `libc` con argomenti arbitrari è possibile eseguire un qualsiasi comando sulla macchina in cui si sta eseguendo il programma, oppure chiamando la funzione `mprotect` (sempre nella `libc`) con gli opportuni argomenti si possono modificare i permessi della pagina di memoria dove risiede lo stack, rendendola eseguibile. A quel punto redirezionare il flusso del programma sul codice iniettato sullo stack non ne provocherà l'arresto. La tecnica funziona perché il codice ad essere eseguito risiede in un area di memoria eseguibile. Una tecnica per mitigare questo tipo di attacco è la casualizzazione dello spazio degli indirizzi (*Address Space Layout Randomization*). Le librerie vengono mappate ad indirizzi di memoria casuali, che cambiano da esecuzione ad esecuzione del programma. In questo modo non si conoscono gli indirizzi delle funzioni e un attacco di tipo *return-to-libc* naive non risulta possibile. Tuttavia su 32bit e sotto alcune condizioni questi indirizzi possono essere facilmente ricavati con un attacco a forza bruta[18]. Anche se su un'architettura 64bit un attacco a forza bruta non risulta fattibile è tuttavia possibile che si riesca a sfruttare qualche altro errore di programmazione per ottenere l'indirizzo della libreria, riuscendo

così a montare comunque l'attacco.

Una generalizzazione della return-to-libc è la tecnica che prende il nome di *Return Oriented Programming*[17, 13]. In questo caso il flusso viene redirezionato non più all'inizio di una funzione, ma all'inizio di una piccola serie di istruzioni, già presenti in un'area di memoria del programma marcata come eseguibile, seguita da un'istruzione *ret*. L'istruzione *ret* preleva dalla memoria dello stack un indirizzo e ridireziona il flusso del programma a quel dato indirizzo. Viene utilizzata al termine dell'esecuzione di una funzione per tornare alla porzione di codice che l'ha richiamata. Potendolo controllare l'attaccante può sistemare lo schema dello stack in modo che una volta che il programma arrivi all'istruzione *ret*, sullo stack sia presente l'indirizzo di una seconda serie dalle caratteristiche simili alla prima. Ripetendo lo stesso discorso più volte è possibile concatenare un numero arbitrario di queste piccole serie di istruzioni (che prendono il nome di *gadget*). In [14] è stato dimostrato che, quando sono presenti opportune tipologie di *gadget*, utilizzando il ROP si possono effettuare computazioni turing-complete. Utilizzando opportune sequenze di *gadget* è possibile applicare tecniche per eludere varie misure di protezione [15].

Un programma può essere compilato affinché il suo codice sia indipendente dalla posizione in cui viene mappato in memoria (*Position Independent Code*), in questo modo non solo le librerie, ma anche il programma stesso può essere caricato in un indirizzo casuale di memoria, che cambia tra un'esecuzione e l'altra. In questo caso non è più facilmente possibile montare un attacco che sfrutti i *gadget*, in quanto la posizione degli stessi non è nota. Altre tecniche sono state sviluppate per mitigare attacchi di tipi ROP, anche se non risultano efficaci o l'overhead è troppo grande [6].

La *Satisfiability Modulo Theories*[3] è un'estensione della logica del primo ordine, che viene estesa con teorie come quella dei bitvector e degli array, rendendolo un ottimo strumento per la modellazione dell'architettura di un elaboratore (specialmente dei registri e della memoria). Negli ultimi tempi è stata dedicata molta attenzione all'utilizzo di risolutori di formule SMT con applicazione nell'ambito della sicurezza[] informatica. Riuscendo infatti a modellare le istruzioni e il contesto di esecuzione di un programma in formule SMT, il risolutore può essere utilizzato, ad esempio, per verificare che un programma aderisca ad una data semantica o per estrapolarne la semantica stessa.

Anche la simulazione simbolica viene utilizzata sempre di più nell'ambito

della sicurezza. Ad esempio può essere utilizzata per mettere in relazione dati in ingresso e comportamento del programma. Semplificando, una volta trovato un modo per poter simulare il programma, ad un valore concreto di ingresso viene sostituito un valore simbolico. Ogni volta che questo valore viene manipolato viene tenuta traccia delle operazioni effettuate su di esso. Le strutture dati del programma possono essere espresse in funzione di quel dato valore simbolico. È possibile poi ricavare in modo automatico una formula SMT che rappresenti queste relazioni, in modo da poter interrogare un risolutore per chiedere, ad esempio, per quali valori in ingresso il programma segua o meno una branch o per quali valori una struttura dati contenga o no un dato valore.

Nell'ambito del ROP un risolutore SMT può essere utilizzato sia per estrapolare in maniera automatica la semantica di un gadget, sia per ottenere le condizioni di partenza che consentano ad un gadget di eseguire una determinata funzione (ad esempio i valori di registro per i quali un dato gadget scrivi in una specifica locazione di memoria un dato valore).

Lo scopo di questo lavoro di tesi è lo sviluppo di uno strumento che possa aiutare nel compito di generare una catena di gadget che sia in grado di prendere controllo di un programma, premesse alcune condizioni. In particolare lo strumento riesce a generare catene di gadgets per eludere misure di sicurezza come stack non eseguibile, casualizzazione dello spazio degli indirizzi e casualizzazione dello stack applicando, in maniera automatica, tecniche come *got patching* e *return to plt* [15]. Lo strumento utilizza per l'analisi del binario il recente framework di sviluppo BARK [10] e supporta l'architettura intel a 32bit e a 64bit.

Descrizioni dei capitoli...

Capitolo 2

Exploit

L'utilizzo di varie tecniche di protezione hanno reso sempre più difficile lo sfruttamento di errori nell'esecuzione di un programma al fine di prenderne il controllo. Questo capitolo introduce brevemente alcune di queste tecniche e analizza con quali metodi è possibile eluderle. Anche se alcuni concetti sono indipendenti dall'architettura e dal sistema operativo questo capitolo tratterà esclusivamente di come queste tecniche sono implementate in ambiente GNU/Linux, su architettura 8086 e amd64. Nella prima parte di questo capitolo si parlerà brevemente dei principali meccanismi con i quali il sistema operativo, partendo dalle informazioni presenti all'interno di un file oggetto eseguibile, crea una rappresentazione dinamica del programma, detta *immagine del processo*. Una volta creata l'immagine del processo il controllo viene ceduto al programma che inizia la sua esecuzione. La prossima sezione si soffermerà solo sulle parti rilevanti per il lavoro svolto.

2.1 ELF, loading

ELF (Executable and Linkable Format) viene utilizzato per rappresentare tre tipi di file oggetto:

- *file oggetto rilocabile*: contiene dati e codice che vengono collegati ad altri file oggetto al fine di ottenere un *file oggetto eseguibile* o un *file oggetto condiviso*
- *file oggetto eseguibile*: è la rappresentazione statica di un programma che può essere eseguito, questo file ha le informazioni necessarie affinché il sistema operativo crei la sua immagine di processo

- *file oggetto condiviso* che contiene codice e dati adatti per essere collegati (nel processo di linking) in due contesti differenti. Può essere infatti utilizzato sia in fase di building insieme ad altri file oggetto rilocabile o file oggetto condivisi (*linking statico*) per creare altri file oggetto, oppure può essere collegato in fase di creazione dell'immagine del processo di un file oggetto eseguibile (*linking dinamico*).

Il formato ELF può contenere sia le informazioni necessarie per processi relativi alla fase di creazione di diversi file oggetto a partire da file sorgente (in particolare informazioni necessarie per la fase di linking), sia relativamente allo scopo della creazione dell'immagine di un processo a partire da un file oggetto eseguibile. Anche le strutture dati all'interno dell'ELF responsabili di questi due “punti di vista” sono differenti, e, a seconda della tipologia del file oggetto alcune delle strutture dati possono non essere presenti. Essendo più rilevante ai fini del nostro lavoro ci concentreremo principalmente sulle strutture dati rilevanti nelle operazioni di creazione dell'immagine del processo e nelle procedure di dynamic linking, ovvero nel processo con il quale si rendono fruibili all'eseguibile i metodi esposti da una libreria condivisa a tempo di esecuzione.

2.1.1 Program header table

L'ELF header (che è l'unica struttura dati che ha una posizione fissa all'interno del file) funge da una sorta di mappa, e ci consente di localizzare tutte le altre strutture dati presenti nel file.

Tra queste vi è la *Program header table*. La program header table è un array di strutture, ognuna delle quali contiene o informazioni su come costruire un segmento della memoria dell'immagine di un processo o informazioni per la preparazione dell'immagine stessa. Una entry all'interno della program header table (su un'architettura a 32bit) è rappresentata dalla seguente struttura C:

```
1 typedef struct {
2     uint32_t    p_type;
3     Elf32_Off   p_offset;
4     Elf32_Addr  p_vaddr;
5     Elf32_Addr  p_paddr;
6     uint32_t    p_filesz;
```

```
7   uint32_t    p_memsz;  
8   uint32_t    p_flags;  
9   uint32_t    p_align;  
10  } Elf32_Phdr;
```

Listing 2.1: program header table entry

La struttura relativa ad un'architettura a 64bit è pressoché identica, l'unica differenza sta nella posizione degli attributi. L'attributo `ptype` indica il tipo di entry. Per il nostro scopo ci limiteremo a descrivere le entry di tipo `PT_LOAD`, `PT_INTERP` e `PT_DYNAMIC`. Le entry di tipo `PT_LOAD` rappresentano informazioni su un segmento da caricare in memoria. Il campo `p_offset` e `p_filesz` indicano rispettivamente l'offset e la sua grandezza all'interno del file. `p_vaddr` e `p_memsz` invece indicano rispettivamente il base address nel quale caricare in memoria il segmento e la dimensione che avrà in memoria (che potrebbe essere più grande rispetto a quella sul file). `p_flags` è molto rilevante per il nostro lavoro e indica con quali flags il segmento andrà ad essere caricato in memoria ovvero se il segmento sarà o meno scrivibile, leggibile e/o eseguibile. Tuttavia nel caso il segmento contenga codice compilato affinché risulti indipendente dal indirizzo base nel quale risiede in memoria, il campo `p_vaddr` potrebbe essere nullo e la posizione del segmento in memoria potrebbe essere casualizzata.

La voce all'interno della program header table con il tipo `PT_INTERP` invece contiene una stringa che rappresenta il percorso di un file oggetto eseguibile o condiviso all'interno del filesystem, detto interprete. Il sistema operativo crea l'immagine del processo dell'interprete, dandogli il controllo. Sarà compito poi dell'interprete creare l'immagine del processo necessaria all'esecuzione dell'eseguibile. Affinché questo possa accadere l'interprete avrà accesso alle informazioni presenti nel file principale. Normalmente l'interprete è costituito da codice indipendente dalla posizione nella quale viene caricato, che viene casualizzata evitando conflitti tra gli spazi di memoria utilizzati dall'eseguibile principale e quelli dell'interprete stesso.

Quando viene creato del codice oggetto che utilizza delle librerie dinamiche, il linker aggiunge alla program header table un elemento di tipo `PT_INTERPRETER` con impostato come interprete il *dynamic linker*, che si occupa di trovare le librerie necessarie all'eseguibile, caricarle in memoria, caricare in memoria i segmenti dell'eseguibile, risolvere le relocation verso i simboli delle librerie, e ridare poi controllo all'eseguibile stesso. Come ve-

dremo la risoluzione di un simbolo potrebbe essere rimandata fin quando non sia realmente necessario. A supporto di questi processi troviamo alcune strutture dati, anch'esse aggiunte al file oggetto eseguibile durante la fase di linking. Queste strutture risiedono all'interno di segmenti che vengono caricati in memoria, e sono quindi disponibili durante l'esecuzione del programma. Informazioni su dove trovare queste strutture dati possono essere ricavati attraverso un'altra struttura dati del file ELF, la *Section header table*, che è un array di strutture che descrivono, per l'appunto, le parti che compongono il file. Tuttavia, anche se anche nel nostro lavoro di tesi le section vengono utilizzate per ottenere informazioni sul binario esaminato, è da notare che esse non sono necessarie per un file oggetto di tipo eseguibile. Un file oggetto infatti può essere caricato esclusivamente con le informazioni presenti nella program header table (lo strumento `ssstrip`[11] elimina appunto le sezioni da un file eseguibile). Tuttavia è conveniente per scopi illustrativi riferirsi alle strutture dati relative al processo di dynamic linking esaminandone le rispettive sezioni:

- Una sezione `.dynamic` che contiene gli indirizzi di altre strutture necessarie al processo di dynamic linking e la lista delle librerie necessarie all'esecuzione del file oggetto eseguibile
- Una sezione `.hash` che contiene una tabella dei simboli
- Le sezioni `.got` e `.plt` contengono rispettivamente due tabelle: *la global offset table* e *la procedure linkage table*. Nelle sezioni successive vedremo come queste due strutture dati vengono utilizzate dal dynamic linker per risolvere i simboli e le chiamate a funzioni presenti nelle librerie dinamiche

2.1.2 Global Offset Table e Procedure Linkage Table

Un programma che sia indipendente dalla posizione in cui viene caricato in memoria non può contenere al suo interno indirizzi assoluti. Le global offset table (GOT) contengono indirizzi assoluti in un'area di memoria privata destinata ai dati, non compromettendo quindi il fatto che il codice sia indipendente dalla posizione (e quindi che sia condivisibile da più immagini di processo, come nel caso di una libreria dinamica). Il linker, una volta creata l'immagine di un processo, processa tutte le rilocalizzazioni (strutture dati che contengono informazioni per la risoluzione dei simboli) di tipo

R_386_GLOB_DAT e per ognuna di esse calcola l'indirizzo assoluto. Il linker conoscendo l'indirizzo di tutti i file oggetto caricati in memoria ha tutte le informazioni necessarie per calcolare il valore di questi indirizzi. Una volta calcolati il linker inserisce i valori assoluti nei rispettivi elementi della GOT, permettendo all'eseguibile di accedervi attraverso posizioni relative.

A noi interessa principalmente come la GOT è coinvolti nel momento in cui un file oggetto eseguibile esegue una chiamata ad una funzione di una libreria dinamica, processo in cui è coinvolta anche una seconda tabella, la procedure linkage table (PLT).

La procedure linkage table redireziona chiamate a funzioni che non siano dipendenti dalla posizione a valori assoluti non conosciuti al momento della fase di linking di un eseguibile. Infatti in fase di building di un eseguibile il linker fa in modo che le chiamate a queste funzioni vengano direzionate a elementi della PLT. Anche se la PLT risiede nel segmento di memoria destinato a contenere il codice di un eseguibile, utilizza valori nella global offset table, non compromettendo così né l'indipendenza dalla posizione né la condivisibilità del codice. È compito del dynamic linker calcolare i valori degli indirizzi della funzione e impostarli nei relativi elementi della GOT. Nella restante parte di questa sezione andremo a descrivere come il dynamic linker utilizza queste due tabelle per risolvere gli indirizzi. È da notare che faremo riferimento all'implementazione su un'architettura a 32bit. Tuttavia il concetto principale resta pressoché invariato anche per un'architettura a 64bit. La PLT è strutturata come nel listato 2.2.

```
1  .PLT0:
2      pushl    got_plus_4
3      jmp     *got_plus_8
4      nop;     nop
5      nop;     nop
6  .PLT1:
7      jmp     *name1_in_GOT
8      pushl    $offset
9      jmp     .PLT0@PC
10 .PLT2:
11     jmp     *name2_in_GOT
12     pushl    $offset
13     jmp     .PLT0@PC
14     ...
```

15 ...

Listing 2.2: Procedure linkage table

- Quando viene creata l'immagine del processo i primi due valori nella GOT assumono valori particolari (spiegati di seguito)
- Quando l'eseguibile esegue una chiamata di una funzione in una libreria dinamica il flusso del programma viene indirizzato nella PLT. Nel nostro esempio viene chiamata la funzione `name1`, che avrà come indirizzo di destinazione l'istruzione marcata dall'etichetta `.PLT1`
- Il programma a questo punto esegue un `jmp` all'indirizzo contenuto nell'elemento nella GOT relativo a `name1`. Al momento di caricamento del programma, a eccezione di casi particolari come descritto di seguito, questo elemento è impostato con il valore dell'istruzione successiva al `jmp` stesso, cioè all'istruzione alla linea 7 del listato 2.2
- Il codice a questo punto salva sullo stack l'offset all'interno della tabella delle rilocazioni che permette di individuare la rilocazione relativa al simbolo `name1`. La rilocazione permette di ricavare sia l'elemento della GOT relativo a quel simbolo che il nome del simbolo stesso, fornendo le informazioni necessarie al dynamic linker per capire quale simbolo è stato chiamato e qual'è l'elemento modificare nella GOT.
- A questo punto il programma salta al primo elemento della PLT e, dopo aver salvato sullo stack il secondo elemento della GOT, salta all'indirizzo contenuto nel terzo elemento della got, che dà il controllo al dynamic linker
- Il dynamic linker esamina lo stack, controlla quale simbolo è stato chiamato, calcola l'indirizzo e imposta il valore nell'elemento relativo nella GOT. In questo modo una seconda chiamata a `name1` non causerà una seconda chiamata al linker ma salterà direttamente all'indirizzo corretto

Quest'approccio nel quale gli indirizzi delle funzioni vengono risolti solo al momento in cui vengono chiamate si chiama *lazy binding*. Se il programma viene eseguito con la variabile d'ambiente `LD_BIND_NOW` impostata

gli indirizzi vengono tutti calcolati e scritti nella GOT al momento del caricamento dell'eseguibile. Questo comportamento avviene anche quando si compila un eseguibile con RELRO. Inoltre, in questo caso, una volta modificata la GOT viene resa non più scrivibile, in modo da mitigare attacchi di tipo got patching.

2.2 Return oriented programming

Per mitigare classici attacchi di tipo stack-smashing sono state elaborate diverse tecniche per precludere la possibilità di eseguire il codice iniettato da un attaccante. La prima di queste tecniche è stata implementata in una patch di Solar Designer [7], che modifica lo schema della memoria dell'immagine di un processo al fine di rendere le istruzioni presenti nello stack non eseguibili. Dato che nella maggior parte dei casi l'attaccante utilizzava lo stack come locazione del codice iniettato questa patch rendeva innocui molti di questi attacchi. Una tecnica più completa, chiamata " $W \oplus X$ ", assicura invece che non ci sia una pagina di memoria all'interno del processo che sia scrivibile ed eseguibile nello stesso momento. Per eludere questa tecnica un attaccante è costretto a non utilizzare più codice da lui stesso iniettato ma codice già presente nell'immagine del processo bersaglio (il primo a suggerire quest'approccio è stato Solar Designer [8]). Dato che la libreria C standard è praticamente utilizzata in quasi tutti i programmi Unix e contiene funzioni utili ad un attaccante (come `system` o `execve`) il codice utilizzato solitamente è proprio quello della `libc`, da cui il nome con cui vengono catalogati questo tipo di attacchi: *return-to-libc*. Tra le misure per mitigare attacchi di questo tipo fu ipotizzato la rimozione di alcune funzioni dalle `libc` al fine di rendere questo tipo di attacchi meno efficace. Shacham in [17] ha evidenziato come questo tipo di protezione fosse in realtà inefficace introducendo per la prima volta la tecnica da lui battezzata come *Return Oriented Programming* (ROP), in cui venivano usate piccole serie di istruzioni di codice già presente nell'immagine del processo e non intere funzioni come in attacchi di tipo *return-to-libc*. Anche se, in questa prima applicazione, la tecnica estrapolava queste serie di istruzioni dalla `libc`, in [16] è stato evidenziato come questa tecnica restasse valida nonostante le istruzioni venissero direttamente prelevate dal testo dell'eseguibile e non dalle sue librerie. In questo modo si può utilizzare la ROP per eludere tutta un'altra serie di protezioni che si basano sulla casualizzazione della posizione di aree di memoria chiave all'interno

dell'immagine del processo di un eseguibile (in particolar modo delle aree che contengono le librerie condivise e di quella riservata allo stack) detta appunto *Address Space Layout Randomization* (ASLR). Nell'applicazione della ROP vengono individuate piccole serie di istruzioni con delle particolari caratteristiche, chiamate *gadget*. Arrangiando minuziosamente lo stack si possono eseguire gadget uno dietro l'altro, cicli o computazioni arbitrarie. Un punto importante è che, almeno per quanto riguarda l'architettura intel, possono essere individuate all'interno di un file oggetto molte sequenze di istruzioni che non sono "intenzionali", ovvero inserite dal compilatore come le istruzioni relative alla traduzione di codice sorgente. Infatti, essendo la codifica delle istruzioni in linguaggio macchina molto densa e non allineata, se si iniziano ad interpretare le istruzioni partendo dal centro di un'altra istruzione, vi è molta probabilità di decodificare una sequenza di istruzioni alternativa e valida. Questo è dovuto alla natura stessa della codifica, quello che Shacham chiama geometria.

2.2.1 Gadget

In questa sezione analizzeremo più in dettaglio i gadget e le loro caratteristiche. Bisogna innanzitutto considerare che essendo i gadget composti da una piccola serie di istruzioni questo tipo di attacchi agisce ad un livello più basso rispetto a quello degli attacchi di tipo return to libc. I gadget possono essere visti come delle istruzioni di basso livello di uno strano calcolatore. Queste istruzioni non vengono concatenate in maniera standard ma arrangiando minuziosamente i valori presenti nello stack. I gadget sono terminati dall'istruzione `ret` e nelle istruzioni che lo compongono non sono contenuti salti e altre istruzioni che deviano in qualche modo il flusso del programma (tecniche che utilizzano anche questo tipo di gadget sono state sviluppate, come in [?]). Aggiuntando lo stack in modo che nel momento in cui il flusso del programma arrivi all'istruzione `ret` di un gadget il registro dello stack punti alla zona di memoria che contiene l'indirizzo del prossimo gadget si riesce a concatenare un gadget al successivo. I gadget, soli o in combinazione, possono svolgere diverse funzioni. Per quanto riguarda, ad esempio, le operazioni di lettura o scrittura possiamo notare che:

- gadget del tipo `pop REG;ret` ci permettono di caricare una costante in un registro

- gadget del tipo `mov reg1, [reg2 + imm]; ret` ci permettono di leggere un valore dalla memoria (il valore di `reg2` può essere impostato con un gadget del punto precedente) e scriverlo su un registro
- gadget del tipo `mov [reg1 + imm], reg2` ci permettono di scrivere in una posizione di memoria (i valori di `reg1` e `reg2` possono essere impostati con gadget che ci consentono di caricare una costante di un registro)

In base all'eseguibile che stiamo considerando però potrebbero non essere disponibili gadget esattamente come questi. In particolare potrebbero presentarsi altre istruzioni tra quella che a noi effettivamente interessa (perché svolge la funzione a noi "utile") e l'istruzione `ret`. A volte modificando opportunamente lo stack si può fare in modo che gli effetti di queste istruzioni non incidano sulla nostra computazione. Ovviamente altri gadget, o sequenze di gadget, possono svolgere funzioni equivalenti e, il fatto che una categoria di gadget non è disponibile non implica che la stessa funzione non possa essere svolta utilizzando gadget e/o strategie differenti. Ad esempio se non abbiamo a disposizione un gadget che ci permetta di impostare il registro `eax` tramite `pop eax; ret` un'opportuna combinazione di `mov eax, 0xFFFFFFFF; ret` e `inc eax; ret` ci permette (non considerando restrizioni sulla lunghezza del payload) di impostare valori arbitrari in `eax`. Estrapolare, in maniera automatica, sequenze e combinazioni di gadget che ci permettano di raggiungere condizioni desiderate o gestire gli effetti secondari delle istruzioni "superflue" è uno dei maggiori problemi di questo lavoro di tesi.

Le operazioni che l'architettura ci permette di eseguire non si limitano ad operazioni di lettura e scrittura. Infatti possiamo eseguire operazioni aritmetiche, operazioni logiche e utilizzare sequenze di gadget che ci permettono di controllare il flusso del programma. Come considerato nel paragrafo precedente spesso i metodi per eseguire queste operazioni non sono diretti, ma è necessario considerare gli effetti secondari e operare solo con i gadget a disposizione. Ad esempio possiamo avere a disposizione solo operazioni che operano su dimensioni di un byte, e per eseguire operazioni su dimensioni maggiori è necessario concatenare più volte la stessa operazione eseguendola un byte per volta, oppure un'operazione potrebbe essere eseguita utilizzando una serie di più operazioni ma che nel complesso sia equivalenti all'operazione voluta.

2.2.2 Address Space Layout Randomization

L' *Address Space Layout Randomization* (ASLR) è una tecnica di protezione che consiste nel caricare in posizione casuale regioni della memoria del programma. Questo è possibile perché un'istruzione può riferirsi ad una locazione di memoria tramite la distanza tra il proprio indirizzo (contenuta nel registro instruction pointer) e la locazione. Non utilizzando quindi più indirizzi assoluti il codice può risultare indipendente dalla posizione di memoria in cui è caricato a patto che gli offset relativi restino invariati (cioè che il codice non venga "mischiato"). Il dynamic linker e alcune strutture dati vengono utilizzate per far funzionare porzioni di codice indipendenti anche dagli offset relativi (come nel caso del testo dell'eseguibile e le librerie dinamiche), utilizzando un livello di indizione (vedi sez. 2.1.1 e 2.1.2).

L'utilizzo dell'ASLR porta due complicazioni principali nell'utilizzo di tecniche basate sulla ROP. Prima di tutto non conoscendo l'indirizzo di una porzione di codice non si possono conoscere neanche gli indirizzi dei gadget contenuti all'interno. Questo riduce notevolmente la quantità di gadget a disposizione, e, a seconda di quanto codice venga casualizzato può rendere impossibile un attacco che utilizzi la ROP. Infatti anche se solitamente, per questioni di efficienza, solo le librerie vengono casualizzate, è possibile compilare un'eseguibile in modo che una volta eseguito tutte le aree che contengono codice vengano casualizzate (*Position Independent Executable* (PIE)). In quest'ultimo scenario, a meno di non ottenere informazioni sulla posizione di memoria in altri modi (ad esempio tramite altre vulnerabilità che esponga indirizzi di strutture dell'eseguibile), l'applicazione della ROP non risulta possibile.

Inoltre a venire casualizzate non sono solo porzioni che contengono codice, ma anche la porzione di memoria riservata allo stack. Non conoscendo la posizione dello stack risulta molto più difficile creare sequenze di gadget che possano eseguire operazioni di controllo del flusso. Una possibile soluzione potrebbe essere quella di iniettare gli indirizzi dei gadget in un'altra posizione (nota) e modificare il valore del registro dello stack perché punti a quella zona di memoria, ovvero creare un *Fake stack frame*. In più non avendo più accesso a librerie dinamiche come la libc, difficilmente si riesce a trovare nella porzione di codice non casualizzato istruzioni che ci consentano di lanciare una syscall (solitamente il programma fa affidamento alla libreria C per eseguirle e quindi dovrebbe comparire tra le sequenze di istruzioni non

“intenzionali”). Tuttavia in [16] è stato dimostrato come anche utilizzando gadget che si incontrano in porzioni di codice relativamente piccole è possibile eseguire computazioni arbitrarie, addirittura concatenando questi gadget in maniera automatica. In più come vedremo nelle prossime sottosezioni è possibile, sotto alcune condizioni, ricavare gli indirizzi di funzioni presenti nella libc partendo dalle strutture dati coinvolte nelle operazioni di dynamic linking. Se le giuste tipologie di gadget sono disponibili è possibile quindi eseguire comandi arbitrari (come lanciare una shell) anche in contesti in cui stack e librerie sono casualizzati.

2.2.3 Return-to-plt, GOT dereferencing e GOT patching

In questa sottosezione presupponiamo che il codice del testo dell'eseguibile non sia stato casualizzato. Anche se le librerie sono casualizzate se un'eseguibile utilizza una funzione presente in una libreria dinamica il linker, in fase di building, inserisce un elemento della PLT relativo a quella funzione (vedi sez. 2.1.1). Se la posizione in cui viene caricato il codice è nota lo è anche quella della PLT e quindi l'indirizzo dell'elemento. Questo ci permette di poter “utilizzare” nella nostra catena le funzioni che utilizza l'eseguibile bersaglio, dirottando il flusso all'indirizzo del relativo elemento nella plt, da qui il nome *return-to-plt*. Una volta utilizzata una funzione il valore dell'indirizzo assoluto di quella funzione si verrà a trovare nell'elemento relativo nella GOT (vedi sez. 2.1.2). Come descritto in [15] questo ci permette di utilizzare due tecniche di attacco particolari: *GOT dereferencing* e *GOT patching*. Tutte e due le tecniche utilizzano l'indirizzo assoluto di una funzione contenuto nell'entry relativa nella GOT per calcolare l'indirizzo assoluto di una funzione della libc desiderata, di fatto eludendo l'ASRL. Nella prima tecnica il valore viene letto, modificato tramite un'operazione aritmetica e viene poi eseguito un `jmp` a questo indirizzo. Un esempio di gadget che consentono questo tipo di attacco sono: `add eax, [ebx + off]; ret` e `jmp [eax]`. La seconda tecnica invece modifica l'elemento della GOT relativo in loco, utilizzando poi un *return-to-plt* per richiamare la funzione voluta. Un esempio di gadget che può essere utilizzato per modificare la funzione in loco è:

```
adc byte ptr [esi + 0x5f], bl ; pop ebp ; ret
```

Infatti concatenando quattro istruzioni del genere insieme ad un opportuno gadget che permette di impostare il registro `esi` è possibile aggiungere

un offset arbitrario in una locazione di memoria arbitraria. È da notare che questa tecnica non funziona nel caso la GOT sia in un'area di memoria non scrivibile (ad esempio se l'eseguibile è stato compilato con l'opzione RELRO) ma i gadget utilizzati in questa seconda tecnica sono di un tipo più comune rispetto a quelli utilizzati nella GOT dereferencing.

Capitolo 3

Architettura di Dropper

In questo capitolo si descrive l'architettura alla quale si sta facendo riferimento per lo sviluppo di dropper.

L'obiettivo di dropper è quello di generare, analizzando un file oggetto eseguibile, una catena di gadget che se iniettata nello stack dell'immagine del processo associato a quell'eseguibile, consente di prenderne il controllo, eseguendo un comando arbitrario sulla macchina. Lo strumento deve poter applicare tecniche note per eludere misure di protezioni esistenti come la casualizzazione degli indirizzi (ASRL), l'isolamento delle pagine (NX) o la read-only relocation. Dropper analizza il binario utilizzando alcune delle funzionalità del framework per l'analisi dei binari BARF. Il linguaggio utilizzato per la scrittura di dropper è python. Dropper supporta file oggetto eseguibili di tipo ELF32 e ELF64, architettura intel 8086 e amd 64, su piattaforme GNU/Linux. Dropper, nella sua fase di analisi, estrapola dal file binario i gadgets disponibili, per poi estrapolarne la semantica. Per questi compiti dropper si avvale sia dell'emulazione dei gadget, sia della loro modellizzazione in formule SMT, come descritto più in dettaglio nelle prossime sezioni. Una volta estrapolata la semantica dei gadget è possibile costruire piccole catene di uno o più gadget che consentano di eseguire operazioni particolari (come modificare il valore dello stack, chiamare una funzione, settare un registro, scrivere in memoria, ecc). Dropper assembla queste piccole catene in catene sempre più lunghe che eseguono operazioni più complesse e articolate. La generazione di queste sequenze avviene, nell'implementazione attuale, in maniera programmatica, cioè la procedura per la sua costruzione è codificata in un algoritmo. È interessante esplorare metodi di generazione di sequenze in maniera dichiarativa, ad esempio utilizzando linguaggi di planning come

PDDL[2]. Un primo approccio che utilizza questa strategia è descritto nella sezione 4.4. Una volta codificato il problema in questi termini si può chiedere ad un planner, come se fosse una sorta di oracolo, in che sequenza collegare le varie azioni (cioè le varie sequenze elementari di gadget) per ottenere quello stato. La rappresentazione delle informazioni sulla semantica dei gadget è espressa in questo modo in forma esplicita, e non più codificata in un algoritmo.

Dropper è composto da tre moduli principali:

- dropper: È il modulo che si occupa di (a) leggere il binario, (b) coordinare le operazioni dei restanti moduli, (c) interagire con l'utente per ottenere informazioni aggiuntive sul binario e/o sullo scenario nel quale dev'essere prodotta la catena e (d) scegliere le tecniche da utilizzare per riuscire a generare la catena
- gadgetstools: È il modulo che si occupa dell'estrapolazione, dell'analisi, della scelta e dell'assemblaggio dei gadget da utilizzare nella composizione della catena e dei vari suoi frammenti
- payloadchunk: È il modulo che si occupa di trasformare una sequenza ordinata di gadget in un payload vero e proprio da iniettare sullo stack, gestendo il posizionamento corretto degli indirizzi e dei valori utilizzati dai vari gadget

3.1 Modulo dropper

È il modulo che si occupa di leggere il file binario, interagire con l'utente, scegliere le varie strategie da adottare e di coordinare le azioni degli altri moduli. Il modulo legge il file e istanzia un oggetto di tipo `gadgets tools` che si occuperà di estrapolare i gadgets dal binario e analizzarli. Per il parsing delle strutture dati presenti nell'elf dropper utilizza la libreria `pyelftools` [4]. Combinando le informazioni provenienti da queste sezioni dropper ricava la lista delle funzioni che il file oggetto eseguibile utilizza e le relative entry nella *Procedure Linkage Table* (vedi TODORIF). La presenza di alcune funzioni può semplificare molto la generazione della catena, di fatto trasformandola in una serie di *return-to-plt*. Dropper analizza altre strutture chiave dell'ELF per individuare aree nella memoria dell'immagine del processo dove

è possibile scrivere. L'utente, interagendo con il modulo, fornisce informazioni aggiuntive necessarie alla generazione della catena e linee guida sulla strategia da utilizzare. Tra le informazioni che il modulo non può ricavare automaticamente troviamo:

- La possibilità da parte dell'utente di controllare un file descriptor
- I file oggetto condivisi utilizzati dall'eseguibile sulla macchina dove si intende far eseguire la catena (per la ricavazione degli offset da utilizzare nelle tecniche di sovrascrizione della GOT Table vedi TODO)
- Eventuali caratteri che non possono comparire all'interno del payload
- Eventuali limiti sulla lunghezza dei payload
- Il comando da eseguire

Con tutte queste informazioni il modulo può quindi procedere nello stabilire quale strategia utilizzare e richiedere al modulo gadgetstools le sequenze di gadget necessarie. Lo schema principale, con alcune varianti che analizzeremo in seguito, si può dividere in due fasi: (a) preparare gli argomenti per eseguire una chiamata ad una funzione di libreria che ci consenta di eseguire un comando arbitrario e (b) eseguire quella funzione.

Alcune delle strategie che si possono utilizzare per raggiungere il primo scopo insieme alle precondizioni necessarie sono elencate di seguito:

- Utilizzo della funzione read

Condizioni necessarie:

- Controllo di un file descriptor da parte dell'utente
- Utilizzo da parte del file eseguibile della funzione read o possibilità di richiamarla attraverso tecniche basate sulla ricavazione degli indirizzi partendo da indirizzi nella GOT e offset relativi

Viene richiamata la funzione read, impostando gli argomenti in modo che i dati letti dal file descriptor vengano scritti nell'area di memoria voluta

- Utilizzo di gadget per la scrittura della memoria

Condizioni necessarie:

- All'interno del file oggetto eseguibile deve essere presente almeno un gadget in grado di scrivere in memoria un valore arbitrario
- I valori da scrivere nella memoria non possono presentare caratteri che non possono essere presenti nel payload, essendo essi stessi scritti nel payload della catena generata

Solitamente una sequenza del genere consente di scrivere al massimo 8 byte per volta in un'architettura 64bit (4 byte per volta su un'architettura a 32bit) e sono composte da almeno due gadget (almeno un gadget serve per settare i registri utilizzati del gadget che esegue la scrittura vera e propria). Questa tecnica tende quindi a generare catene piuttosto lunghe se la dimensione dei valori da scrivere in memoria è grande

Queste appena elencate le uniche due tecniche attualmente implementate, strategie alternative potrebbero comprendere:

- Utilizzo delle funzioni `strcpy` o `memcpy` per copiare byte presenti in posizioni note all'interno dell'eseguibile nella posizione desiderata [15]. Questa tecnica, copiando verosimilmente solo un byte per volta tende anch'essa a generare payload abbastanza lunghi
- Nel caso un bug renda possibile la conoscenza dell'indirizzo dello stack gli argomenti possono essere scritti direttamente nello stack

Una volta scritti gli argomenti per la funzione da richiamare in memoria è necessario chiamare la funzione stessa. La funzione deve permetterci di eseguire un comando arbitrario. All'interno della `libc` sono presenti due funzioni con queste caratteristiche: `execve` e `system`. Un ritorno diretto alla funzione solitamente non può avvenire, in quanto il valore del suo indirizzo in memoria è casualizzato. Tuttavia, se una funzione è utilizzata all'interno del programma, basterà ritornare alla sua entry nella Program Linkage Table, che ha una posizione nota e fissa all'interno della memoria dell'immagine del processo. Nel caso invece che la funzione non venga utilizzata un'alternativa è quella di adoperare tecniche per ricavare l'indirizzo della funzione partendo dall'indirizzo di un'altra funzione della stessa libreria che invece viene utilizzata dal programma. Questo funziona perché nonostante l'indirizzo iniziale al quale una libreria viene caricata sia casualizzato, gli offset tra le funzioni non cambiano. Alcune considerazioni sull'utilizzo di questa tecnica:

- Devono essere noti gli offset delle funzioni all'interno del file oggetto condiviso della libreria utilizzato sulla macchina bersaglio (anche se, variando in un range relativamente piccolo, non dovrebbe essere impossibile, se le condizioni lo consentono, montare un attacco di tipo forza bruta per ricavarli)
- il binario deve presentare una sequenza di gadgets che ci consenta di eseguire un'operazione di somma (o un'operazione che ci consenta di simulare una somma, come una sottrazione) tra un offset di tre/quattro byte e un'area di memoria arbitraria (l'area dove è memorizzato l'indirizzo della funzione usata come riferimento, solitamente nella GOT). Molto spesso però abbiamo gadget che ci consentono di aggiungere solo un byte per volta. Questo è un problema perché in un'operazione di somma byte per byte dev'essere considerato un eventuale valore di riporto tra un byte e il successivo. Questo può essere risolto se il tipo di gadget trovato usa un'istruzione di tipo `adc` (add with carry), controllando che tra gli effetti secondari degli altri gadgets non venga modificato il carry flag. In realtà anche non avendo a disposizione questo tipo di gadget, per via dell'allineamento in memoria, gli ultimi bit dell'indirizzo di una funzione non variano tra un'esecuzione e la successiva. Con questa parziale conoscenza del valore iniziale si può comunque creare una catena con un'alta percentuale di successo come descritto in TODO
- Un tipo di attacco di questo tipo può essere mitigato se le rilocalizzazioni vengono impostate come read-only. In questo caso infatti gli indirizzi delle funzioni vengono calcolati tutti al momento di caricamento del programma, e la GOT, una volta modificata opportunamente, viene resa non scrivibile. In questo caso è ancora possibile montare un attacco del genere, ma l'operazione aritmetica non può avvenire direttamente sulla got e non può essere utilizzato un `ret-to-plt` per saltare all'indirizzo calcolato. Bisogna cioè avere a disposizione i gadget necessari per leggere dalla memoria, effettuare l'operazione aritmetica e eseguire un `jmp` al nuovo indirizzo calcolato

È interessante notare come, anche se vi è una guida nelle operazioni da seguire basata sulla strategia scelta, la sequenza di operazioni che conducono allo stato del sistema desiderato sono molteplici. Ad esempio l'operazione

aritmetica per il calcolo dell'indirizzo della funzione bersaglio potrebbe avvenire in memoria, oppure tra due registri e poi salvata in memoria. Qui si notano i vantaggi che potrebbe avere un approccio che modelli la situazione in un problema di planning rispetto ad un approccio di tipo programmatico. Infatti, con un approccio programmatico, tutte le combinazioni vanno codificate nell'algoritmo, una procedura la cui completezza è più difficile da dimostrare e che è molto più soggetta ad errori.

3.2 Modulo gadgetstools

Il modulo gadgets tools si occupa di ricavare i gadgets presenti nel file oggetto eseguibile, di estrarne la semantica e della creazione di sequenze di gadget che se eseguite assolvono funzioni particolari (come scrivere in memoria, settare un registro, ecc.). Questo modulo interagisce con payloadchunk per trasformare sequenze ordinate di gadget in un payload vero e proprio da poter iniettare sullo stack ed espone i metodi per la creazione delle catene che vengono usati dal modulo dropper.

Per la ricerca dei gadget all'interno del file oggetto eseguibile viene utilizzata la classe GadgetFinder del framework BARF, che implementa al suo interno l'algoritmo galileo[14].

Una volta disponibile l'insieme dei gadget presenti nel file oggetto eseguibile bisogna, per ognuno di essi, estrarne la semantica. Per estrarne la semantica si intende estrapolare in maniera automatica gli effetti che una serie di istruzioni hanno sul contesto il quale, semplificando, è rappresentato dalla memoria e dai registri. Per questo tipo di analisi si utilizzano due strumenti principali: la simulazione e la traduzione delle istruzioni in formule SMT. Un'analisi completa della semantica presenta alcuni limiti dovuti alla difficoltà di una modellizzazione completa del sistema nonché alla conoscenza parziale del contesto (memoria e registri) reale in cui si troveranno ad essere eseguite le istruzioni. Ad esempio utilizzando l'attuale traduzione delle istruzioni in formule SMT, è difficile porre al risolutore domande che riguardino il numero di letture effettuate, o domandare se un'area di memoria viene mai letta. L'estrapolazione della semantica di un gadget avviene in tre fasi: (a) emulazione e catalogazione, (b) verifica e validazione e (c) verifica degli effetti secondari.

3.2.1 Emulazione e catalogazione

La classe `GadgetClassifier` emula il gadget tenendo traccia delle operazioni sui registri e sulla memoria. Con questi dati si verifica se il gadget appartiene ad una o più categorie indicate in [16]. Inoltre vengono identificati quali registri vengono utilizzati come “operandi” della funzione alla quale il gadget viene associato. Basandosi su una simulazione e non su un effettiva analisi semantica questa catalogazione deve essere poi verificata. Per le simulazioni vengono utilizzati dati concreti ma una simulazione simbolica, funzionalità ancora non disponibile all’interno del framework BARF, consentirebbe una catalogazione più veloce e accurata esplicitando le relazioni tra i valori che i registri hanno all’inizio e alla fine della simulazione o tra i valori iniziali dei registri e gli accessi alla memoria.

3.2.2 Verifica e validazione

Si deve poi verificare che, anche se il gadget esegua la funzione della categoria alla quale viene assegnato, possa essere utilizzato per i valori di tutto il “dominio” di questa funzione, cioè che non ci siano restrizioni sugli operandi del gadget. Per esempio, un gadget catalogato come `MemoryStore` ma che utilizzi lo stesso registro come operando di destinazione e operando sorgente non può essere utilizzato per scrivere in una locazione arbitraria di memoria un valore arbitrario. Per questa verifica si scelgono casualmente gli effetti che deve avere la funzione sul contesto. Ad esempio se stiamo verificando un `MemoryStore` si sceglie sia una locazione casuale di memoria sia un valore casuale da scrivere in questa locazione. Si traduce il gadget in formule SMT e si impone che il contesto finale rifletta gli effetti, scelti casualmente, che la nostra funzione deve avere. Nel nostro esempio si impone che la locazione di memoria cambi al valore casuale scelto. Si chiede a questo punto al risolutore se il sistema di formule ammette una soluzione. Se il sistema non ammette soluzione il gadget può essere scartato, in quanto non essendo usabile per quei valori perde la sua generalità. Nel caso invece il sistema ammetta soluzione vengono richiesti al risolutore i valori iniziali, all’interno del modello trovato, dei registri che, secondo la catalogazione al punto uno, sono gli “operandi” della funzione. Si impongono poi al risolutore nuovamente le formule SMT che rappresentano il gadget. Questa volta si impongono però come valori iniziali per i registri operandi i valori ottenuti dalla prima verifica e, inoltre, che il valore finale sia diverso da quello aspettato. La non

soddisfacibilità di questa formula ci dà la certezza che in tutti i modelli che soddisfano la semantica del gadget, che hanno come valori iniziali dei registri “operandi” quelli ottenuti dalla prima verifica, lo stato finale del contesto rispecchi i valori attesi. Questa verifica esclude che ci siano effetti secondari che possono interferire con gli effetti della nostra funzione. È da notare che queste proprietà sono verificate solo per dei valori casuali e dovrebbero essere verificate per tutti i valori. Questo non viene fatto sia per motivi di efficienza sia per non includere quantificatori universali nelle formule, complicando di molto il lavoro del risolutore e rischiando di ottenere formule non decidibili. Questo problema può essere risolto ripetendo queste verifiche al momento dell'utilizzo reale del gadget con i valori concretamente utilizzati.

3.2.3 Verifica degli effetti secondari

Il punto precedente ci assicura che un gadget non abbia effetti secondari che interferiscano con gli effetti della nostra funzione. Tuttavia è possibile che il gadget in esame abbia altri effetti secondari che non lo rendano utilizzabile. Ad esempio se il gadget legge da una locazione di memoria non leggibile causerà l'arresto del programma. La modellizzazione in SMT utilizzata attualmente nel framework BARF non consente di porre al risolutore domande sul numero di letture in memoria o sulla lettura o meno di un area di memoria. Per questo motivo per escludere effetti secondari di questo tipo il gadget viene emulato con i valori di ingresso ricavati al punto 2, e ci si assicura che non vengano lette e scritte aree di memoria che non siano quelle relative alla funzione propria del gadget o all'area dello stack.

La linea guida generale appena descritta va adattata alla tipologia di gadget analizzata, per le implementazioni specifiche fare riferimento alla seconda parte di questo capitolo. Inoltre per poter utilizzare un gadget, i registri utilizzati come “operandi” devono essere “controllabili”, cioè deve esistere una serie di gadget che consenta di poter caricare valori arbitrari in questi registri. Per questo prima di procedere alla verifica dei gadget si cercano all'interno dell'eseguibile tutte le sequenze di gadget che ci permettono di controllare registri. Se un gadget utilizza come operandi registri che non sono “controllabili” questo viene scartato.

Inoltre è da notare come la verifica potrebbe avvenire in modo più efficiente, utilizzando delle simulazioni mirate a scartare i gadget che sicuramente non ci consentono di utilizzare valori arbitrari. In questa fase dello sviluppo

del progetto però l'efficienza non viene considerata come prioritaria. Durante queste le fasi di classificazione e verifica vengono anche raccolte informazioni aggiuntive sui gadget, come di come un gadget modifica il valore del registro dello stack e la posizione dello stack dove inserire i valori utilizzati dal gadget. Queste informazioni vengono utilizzate dal modulo PayloadChunk per costruire il payload vero e proprio.

Per le simulazioni viene utilizzata la classe ReilEmulator e la traduzione in formule smt avviene attraverso la classe CodeAnalyzer, entrambe del framework BARF.

3.3 Payload Chunk

Questo modulo si occupa di generare il payload vero e proprio partendo dai gadget analizzati dal modulo gadgetstools. Questa classe è strutturata in modo che i diversi chunk prodotti siano concatenabili, e che la loro concatenazione dia a sua una volta un frammento concatenabile. Questo ci consente di associare ad una data funzione un payload e utilizzarlo in diverse parti del programma senza dover più conoscerne i dettagli. Ci sono diverse cose da tenere in conto quando si costruisce il payload partendo dai gadgets, quasi tutte legate alla manipolazione dello stack da parte del gadget stesso:

- posizioni dei valori utilizzati dal gadget in relazione alla valore puntato dallo stack al momento della sua esecuzione
- valore al quale punterà lo stack al momento dell'esecuzione dell'istruzione ret del gadget stesso. In base alla tipologia di gadget questo valore potrebbe non essere alla fine del payload relativo al gadget stesso
- valore finale dello stack dopo l'esecuzione del gadget

Le informazioni relative alle tre problematiche descritte sopra vengono estrapolate dal gadgetstools. La procedura di generazione del payload è specifica del tipo di gadget, i metodi PayloadChunk.chain e PayloadChunk.get_general_chunk sono invece generici, prendono come argomento una lista di chunk e restituiscono rispettivamente il payload dei chunk concatenati o un chunk che può essere nuovamente concatenato e rappresenta la concatenazione dei chunks in ingresso.

Capitolo 4

Implementazione di Dropper

In questo capitolo si farà un'analisi dell'attuale stato di sviluppo di dropper.

4.1 Dropper

4.1.1 Interazione con l'utente

Attualmente dropper si interfaccia all'utente tramite alcune funzioni della classe dropper. Il costruttore di questa classe riceve come argomento il percorso sul file system dove risiede il file oggetto eseguibile da analizzare. Le operazioni di analisi vengono avviate tramite la funzione `analyze_all`. Una volta analizzato si può richiamare la funzione `build_spawn_shell_payload` che si occupa di generare la catena vera e propria. Anche se queste sono le uniche chiamate essenziali l'utente ha a disposizione ulteriori funzioni:

- `set_can_control_fd` setta il file descriptor controllato dall'utente (-1 se nessun file descriptor può essere controllato)
- `set_function_for_address_resolving` indica la funzione di riferimento da utilizzare nell'applicazione di tecniche che ricavano l'indirizzo di funzioni casualizzate in memoria partendo da valori nella GOT table. La funzione indicata dev'essere già stata richiamata almeno una volta al momento dell'esecuzione della catena
- `set_writeable_area` setta l'indirizzo di inizio dell'area di memoria dove effettuare operazioni di scrittura. Di default questo valore è settato all'indirizzo di caricamento in memoria della sezione `.data`

- `set_cmd` setta il comando da eseguire sulla macchina bersaglio una volta che l'exploit ha avuto successo

Quando il file eseguibile è stato analizzato e le informazioni necessarie impostate il metodo `build_spawn_shell_payload` cerca di generare una catena che avvii il comando impostato.

4.1.2 Analisi degli import

Se una funzione esterna viene utilizzata dal programma, anche se il suo indirizzo reale viene casualizzato, sarà presente un elemento relativo a quella funzione all'interno della procedure linkage table. Questo elemento, ammesso che il binario non sia stato compilato come indipendente dalla posizione in memoria (PIE), ha una posizione nota. Possiamo quindi ritornare al suo indirizzo per emulare la chiamata a quella funzione (return-to-plt). Nella GOT invece ogni elemento inizialmente, e quindi anche staticamente nel file, contiene l'indirizzo dell'istruzione successiva nell'elemento della PLT relativo alla stessa funzione. Per ogni funzione la rilocazione associata, nella sezione `.rel.plt`, contiene nel campo `r_offset` l'indirizzo dell'elemento nella GOT table. A partire da quest'ultimo, per le considerazioni appena fatte, può essere ricavato l'indirizzo della entry nella PLT. Gli indirizzi del relativo elemento della GOT e di quello nella PLT vengono ricavati per ogni funzione utilizzata dal file oggetto eseguibile nel metodo `get_imports`.

4.1.3 Costruzione della catena

Attualmente il modulo dropper per prima cosa cerca di scrivere in un'area di memoria scrivibile i dati ai quali punteranno gli argomenti dell'invocazione della funzione `execve`. Nel caso quest'area di memoria non viene specificata dall'utente viene utilizzato l'indirizzo di caricamento in memoria della sezione `.data`. Gli argomenti e i dati veri e propri vengono creati dal modulo partendo dal comando che si è deciso di eseguire sulla macchina (nella funzione `payload.execve_args`). Se si può controllare un file descriptor e `read` è presente nell'insieme delle funzioni utilizzate dal programma allora dropper crea una catena che ritorni all'elemento all'interno della PLT relativo a `read` e fa in modo che vengano letti, dal file descriptor indicato, una quantità di dati pari alla dimensione dei dati da scrivere e che essi vengano scritti nell'area di memoria scelta come area scrivibile. Per far questo viene utilizzato il metodo

`get_ret_func_chunk` del modulo `gadgets tool` il quale ci consente di creare una catena che richiami una funzione di cui si conosce l'indirizzo. È compito poi dell'utente fare in modo che al momento della chiamata di questa funzione il file descriptor indicato si trovi nello stato giusto a restituire i valori calcolati dal modulo. I valori da fornire nel file descriptor vengono forniti all'utente nel parametro `fd_payload` di `dropper`. Esempio?

Attualmente è implementata una seconda strategia nel caso non sia presente la funzione `read` e/o non si controlli nessun file descriptor. Essa consiste nell'utilizzare una serie di gadget che possano spostare valori dallo stack in una locazione di memoria arbitraria. Per costruire una catena del genere si chiama la funzione `build_memory_write` del modulo `gadgets tools` che prende come argomenti l'indirizzo della memoria dove scrivere e i dati da scrivere. Solitamente, come vedremo in 4.2.2, le catene generate in questo modo tendono ad essere piuttosto lunghe.

Per quanto riguarda la seconda fase, la chiamata della funzione, sono state implementate solo due strategie. La prima nel caso `execve` sia presente all'interno delle funzioni utilizzate dal programma. In questo caso la generazione della parte restante della catena è banale e, come visto nel paragrafo precedente, viene costruita dalla funzione `get_ret_func_chunk` del modulo `gadgets tools`. Più interessante è il caso in cui il file oggetto eseguibile non utilizzi questa funzione. Una strategia che è possibile adottare in questo caso si basa sul calcolo dell'indirizzo della funzione voluta partendo da una funzione utilizzata dal programma, il cui indirizzo viene ricavato dal relativo elemento nella GOT table. La funzione dev'essere già stata chiamata almeno una volta, questo fa sì che nella GOT table sia presente l'indirizzo reale e non l'indirizzo del relativo elemento all'interno della PLT. L'indirizzo può essere sia calcolato in un registro o in una zona di memoria per poi sfruttare una tipologia di gadget che ci permetta di "saltare" all'indirizzo calcolato (*got dereferencing*). È anche possibile, se l'eseguibile non è compilato con `RORELOC`, modificare il valore della GOT in loco, aggiungendo l'offset necessario (*got patching*). Attualmente è implementata solo la seconda strategia. Il modulo `gadgets tools` espone il metodo `build_memory_write` che si occupa dei dettagli implementativi di questo tipo di catena. Viene chiamato da `dropper` con i seguenti parametri:

- l'indirizzo di memoria dove eseguire la somma: l'indirizzo dell'elemento della GOT da "patchare"

- il valore da aggiungere: l'offset relativo tra la funzione utilizzata come base e quella voluta
- il valore di base: l'offset che la funzione di base ha all'interno del file oggetto condiviso della libreria. Come vedremo questo rende possibile utilizzare la tecnica anche quando le tipologie di gadget disponibili non sono ideali al prezzo di sacrificare un'affidabilità del 100% (vedi sez. 4.2.3)

La classe inoltre contiene alcuni metodi per il salvataggio dei dati relativi ai gadgets su disco, questo perché l'analisi di eseguibili molto grandi può durare diversi minuti. Al loro interno questi metodi utilizzano la libreria pickle per la serializzazione degli oggetti.

4.2 GadgetsTools

Questo modulo estrapola e cataloga i gadget presenti nel binario in esame ed espone i metodi di creazione delle catene per l'esecuzione di diverse funzioni. Le catene vengono costruite arrangiando i gadget disponibili e collaborando con il modulo payloadchunk che si occupa della generazione del payload vero e proprio. Fondamentale per poter utilizzare un gadget è poter controllare i registri coinvolti nelle sue operazioni, per questo motivo la prima analisi che viene condotta una volta ottenuta la lista dei gadget è la selezione di quelli che ci consentono di controllare i registri. La ricerca dei gadget viene effettuata in tutte le sezioni che vengono caricate in memoria (discriminate dal tipo SHT_PROGBITS) e marcate come eseguibili.

4.2.1 Selezione dei gadget per l'impostazione dei registri

La logica e le strutture dati utilizzate per la selezione e la gestione dei gadget utilizzati per l'impostazione dei registri è contenuta nella classe RegSet. Il metodo `_analyze_gadget` riceve come argomento in ingresso un gadget e, nel caso esso possa essere utilizzato per l'impostazione di registri, viene aggiunto nelle strutture dati interne alla classe. La classe espone il metodo `get_chunk` che ritorna una catena che imposta i registri in modo da riflettere le coppie registro/valore del dizionario preso come argomento. Attualmente solo

gadget che contengono istruzioni di tipo `pop reg` vengono considerati come potenziali candidati per l'impostazione di registri. L'analisi avviene tramite la simulazione istruzione per istruzione. Se l'istruzione attuale è di tipo `pop reg` allora si memorizza il nome del registro e l'offset tra il valore attuale dello stack e quello all'inizio della simulazione. Questo ci consente di conoscere dove posizionare il valore da impostare nel registro al momento della generazione del payload. Durante la simulazione si controlla anche che le istruzioni che non sono del tipo `pop reg` non eseguano operazioni di lettura o scrittura sulla memoria. Questo ci consente di scartare già in questa fase i gadget che presentano effetti secondari. Alla fine della funzione abbiamo la lista dei registri che il gadget può impostare con i relativi offset dello stack. La funzione `get_chunk` invece restituisce una catena che consente di impostare l'insieme dei registri che riceve in ingresso. Dato che un gadget potrebbe impostare più di un registro, la scelta dei gadget che andranno a comporre questa catena è riducibile ad un problema di *set covering*. È preferibile che il payload generato dalla catena sia il più piccolo possibile. La lunghezza della catena è influenzata sia dal numero di gadget utilizzati, sia dal padding che è necessario inserire nell'utilizzo di ogni gadget per via delle operazioni che esso effettua sul registro dello stack. Attualmente per trovare la catena viene utilizzato un algoritmo greedy che scorre i registri da "coprire" e, se il registro non è già coperto da un gadget inserito nella catena, sceglie il gadget che lo copre e che necessita del minor padding possibile. Se l'aggiunta di un gadget ne rende superfluo uno già presente nei candidati quest'ultimo viene rimosso. La soluzione trovata con quest'algoritmo non è ottima.

4.2.2 Selezione dei gadget per la scrittura in memoria

La logica e le strutture dati per gestire i gadget che ci consentono di scrivere in memoria si trovano nella classe `MemoryStore`. Durante la prima classificazione la classe `GadgetClassifier` del framework BARF verifica se a seguito di alcune simulazioni un valore presente in un registro (denominato sorgente) viene scritto in una locazione di memoria il cui indirizzo corrisponde al valore di un registro (denominato destinazione) sommato ad un eventuale offset. Ogni volta che questa condizione viene verificata il gadget viene aggiunto alla categoria `StoreMemory`. È da notare che la condizione di cui sopra potrebbe verificarsi per più coppie di registri nello stesso gadget, per ognuna di queste viene creato un oggetto gadget di tipo `StoreMemory` e aggiunto alla

categoria. La classe parte da questi gadget per procedere alla fase di verifica e validazione. Innanzitutto se il registro di destinazione è il registro dello stack il gadget viene scartato. Questo fa in modo che non vengano presi in considerazione i gadget con istruzioni tipo push reg. Questi gadget infatti, solitamente non consentono di scrivere in una regione arbitraria della memoria, oltre a complicare la gestione dello schema dello stack. Dopo di che vengono scartati anche i gadget che hanno come registro di destinazione rip e eip. Infatti essendo questo registro fisso rispetto all'istruzione che lo esegue neanche questi gadget ci consentono di scrivere in una posizione arbitraria di memoria. Dopo di che si procede seguendo le linee guida descritte in 3.2.2: il gadget viene scartato se non si possono controllare i registri sorgente e destinazione, si verifica e valida la generalità e ci si assicura che il gadget non presenti effetti secondari. I valori scelti casualmente per la verifica e la validazione sono la locazione di memoria e il valore da scrivere. Nella verifica degli effetti secondari si controlla che non ci siano scritture al di fuori della locazione scelta e dello stack. Il metodo `get_chunk` invece prende come argomenti un indirizzo in memoria e dei valori e restituisce una catena che scrive i valori in memoria partendo da quell'indirizzo. Il metodo sceglie uno dei gadget disponibili e calcola quante iterazioni sono necessarie per la scrittura dei valori. Per ogni iterazione poi utilizza il risolutore SMT per ottenere i valori dei registri sorgente e destinazione corretti. Sempre per ogni iterazione, si utilizza la classe `regset` per ottenere una catena che setti i registri a quei valori, e la si concatena a sua volta al gadget che si sta utilizzando per scrivere in memoria. Viene restituita la concatenazione delle catene create per ogni iterazione, che verosimilmente scriverà in memoria, partendo dall'indirizzo indicato i valori in ingresso.

4.2.3 Selezione dei gadget per la operazioni aritmetiche in memoria

La logica e le strutture dati per la gestione dei gadget che ci consentono di scrivere in memoria risiedono nella classe `arithmeticmemorystore`. Anche in questo caso si parte dai gadget classificati dal framework BARF, ma appartenenti, per l'appunto, alla categoria Arithmetic Memory Store. Un gadget viene inserito in questa categoria se, dopo alcune simulazioni del gadget, una locazione di memoria viene modificata e come valore finale riflette il risultato di un'operazione aritmetica binaria tra il valore precedente di quella locazio-

ne e il valore iniziale contenuto in un registro. Inoltre si individua un registro che potrebbe essere usato dal gadget come indirizzo della locazione di memoria (insieme ad un eventuale offset). Dato che la simulazione viene ripetuta più volte i falsi positivi vengono ridotti. È possibile che un gadget esibisca il comportamento di cui sopra più di una volta, anche in questo caso vengono creati diversi oggetti di tipo Arithmetic Memory Store. L'analisi di questi gadget procede, come anche nella categoria precedente, sulla falsa riga della procedura indicata in 3.2.2. Tuttavia un'attenzione particolare va posta nell'analisi dei gadget che utilizzano un'operazione di addizione che considerano il valore di riporto (ad esempio `adc` su intel). Questi gadget possono rivelarsi molto utili. Spesso infatti sono disponibili solo gadget aritmetici che ci consentono di aggiungere un byte per volta. Effettuare un'operazione di `got patching` (vedi sez. ??) un byte per volta senza considerare i valori di riporto tra un byte e il successivo può portare ad un risultato errato dell'operazione che si sta effettuando. Per poter permettere la cataloghizzazione di questo tipo di gadget, si è dovuto applicare una piccola patch al framework per permetterci di poter controllare in qualche modo il contesto dei registri che utilizza durante le simulazioni per la classificazione. Infatti il classificatore, nella traduzione in `reil`, considera il flag `carry` del registro dei flag come un registro a se stante di 16bit che viene aggiunto al risultato dell'operazione. Dato che questo valore è impostato casualmente i risultati delle simulazioni vengono falsati. La nostra modifica ci permette di settare un valore arbitrario per alcuni registri nelle simulazioni, quindi inizializzeremo il "registro" con il quale è rappresentato il `carry flag` a zero. Questo viene anche imposto nelle verifiche che utilizzano un risolutore SMT. In più viene aggiunta una seconda coppia di modellazioni SMT con le quali si verifica se il gadget in esame utilizza il `carry flag` nell'operazione e se a seguito di un'operazione che sicuramente generi un valore di riporto, il `carry flag` al termine del gadget abbia valore uno. Questo ci dà la certezza rispettivamente che il gadget va ad utilizzare il `carry flag` nelle operazioni di addizione e che le operazioni successive all'interno del gadget non vadano ad influenzare il `carry flag`. Come detto sopra, per costruire una catena che ci consenta di aggiungere un valore arbitrario ad una locazione di memoria arbitraria, bisogna avere a disposizione o gadget aritmetici la cui dimensione dell'operazione sia di almeno un byte più grande dell'addendo o un gadget che, per l'appunto, consenta di eseguire operazioni utilizzando i valori di ritorno. In questo secondo caso però bisogna anche concatenare, se è disponibile, un gadget che abbia come effetto quello

di azzerare il carry flag, da inserire prima dell'operazione. La logica per la ricerca di questo tipo di gadget è presente nella classe `ClearCarryFlag`. È da notare che se questo tipo di gadget non fosse presente la catena generata potrebbe non avere l'esito sperato, tuttavia è presumibile che in molti tipi di exploit il carry flag abbia sempre lo stesso valore all'inizio dell'esecuzione della catena. La sottrazione quindi di un'unità al primo byte dell'offset dovrebbe essere sufficiente per generare una catena corretta. Se non sono disponibili né un gadget che consenta di aggiungere abbastanza bytes per volta né un gadget che effettua operazioni considerando il valore di riporto è tuttavia possibile generare una catena con alte probabilità di successo. Infatti l'indirizzo di memoria nel quale viene caricato il file oggetto condiviso della libreria, nonostante sia casualizzato, dev'essere allineato in memoria al valore specificato nel parametro `p_align` all'interno del program header. Questo comporta che un certo numero di bits meno significativi dell'indirizzo di una funzione non cambino da un'esecuzione all'altra. Solitamente sono i 21bits meno significativi, e l'offset tra due funzioni nella libc solitamente è tre byte. Questo fa sì che si può calcolare il valore di riporto per i primi due byte. Solo il valore di riporto dell'ultimo byte (di cui conosciamo solo la parte meno significativa) risulterebbe casuale, facendo sì che si possano generare catene con probabilità di successo pari almeno al 50%.

È da notare che nell'implementazione attuale manca ancora l'implementazione della logica per la ricerca e la verifica di importanti categorie di gadget (come `Jump`, `MemoryLoad`, `MoveRegister` o `Arithmetic`). L'implementazione di queste categorie dovrebbe consentire la generazione di catene in condizioni più articolate o quando le categorie di gadget attualmente implementate non sono disponibili.

4.3 PayloadChunks

Questo modulo si occupa di generare a partire da una lista ordinata di uno o più gadgets un array binario di dati da iniettare nello stack del file oggetto eseguibile esaminato. La preparazione del payload varia rispetto al gadget per il quale si sta creando il chunk e può consistere nel solo indirizzo del gadget, o in schemi più complicati come indirizzi di funzioni più relativi argomenti o a valori da trasferire dalla stack ai registri. Ogni classe che si occupa della generazione di un particolare tipo di chunk ha le informazioni necessarie per permettere al chunk stesso di essere concatenato ad altri chunk

per generarne un altro, anch'esso a sua volta concatenabile, che rappresenti i chunk di partenza. Per permettere questa concatenazione ogni chunk deve presentare le seguenti informazioni:

- L'indirizzo che deve trovarsi sullo stack al momento dell'esecuzione dell'istruzione `ret` del gadget precedente
- In quale posizione del payload inserire l'indirizzo del gadget successivo
- La dimensione degli indirizzi nell'architettura considerata

Le classi che modellano i vari tipi di chunk hanno tutti un metodo, `get_payload`, che restituisce il payload del chunk di riferimento (escluso l'indirizzo del gadget stesso). Quando due gadget vengono concatenati per generare un chunk più generico (nel metodo `PayloadChunk.get_general_chunk`), l'indirizzo di ogni chunk viene inserito nella posizione indicata dal chunk precedente. Nel momento che si richiede il payload vero e proprio (attraverso il metodo `PayloadChunk.chain`) oltre all'operazione di concatenazione viene anche inserito l'indirizzo del primo gadget all'inizio del payload.

4.4 Utilizzo di pianificatori per la costruzione della catena

Il problema di generare una catena (quindi una sequenza) di gadget (che possono essere visti come azioni) per arrivare ad uno stato del sistema desiderato si traduce naturalmente in un problema di planning. Una volta tradotto si può utilizzare un planner per ottenere una soluzione valida e/o (dipende dal planner che si utilizza) ottima. PDDL è un linguaggio che ha come obiettivo quello di dare uno strumento universale per codificare problemi di planning. In questa sezione esamineremo un primo approccio che può essere utilizzato per tradurre il nostro problema nel linguaggio PDDL. Il linguaggio divide il problema in due descrizioni differenti, una che si occupa di definire il dominio del problema, l'altra di definirne una singola istanza. Nella definizione del dominio vengono descritti i tipi di oggetto che avremo nel nostro sistema, gli oggetti presenti in tutte le istanze (*constants*), i *fluents*, e le azioni, insieme agli effetti che queste hanno sugli oggetti del dominio. Una singola istanza del problema invece definisce gli oggetti che le azioni possono manipolare, lo

stato iniziale nel quale si trova il sistema, lo stato che vogliamo raggiungere e la metrica con la quale valutare la bontà di un piano. Un *fluents* è un mapping tra una tupla di oggetti e un valore numerico che può cambiare durante un piano. La loro sintassi e semantica è stata stabilizzata nel linguaggio in [9]. Come evidenziato in [9] i fluents non possono essere utilizzati come parametri di azioni perchè queste agiscono su oggetti “fisici” e quindi i parametri devono appartenere ad insiemi finiti (e non ad insiemi infiniti come i numeri). Per ovviare a questa limitazione utilizzeremo come stratagemma quello di creare degli oggetti di tipo *imm* e associando tramite il fluent *val* (*?x - imm*) un valore a quel dato oggetto. Questo farà sì che le azioni possono utilizzare parametri di tipo *imm*.

I tipi di dato utilizzati nella modellazione sono *imm*, con il significato appena spiegato, e *register* che rappresenta per l'appunto un registro. I fluent utilizzati invece sono:

- (*val ?x - imm*) come appena definito
- (*reg ?r - register*) che rappresenta il valore attuale del registro *?r*
- (*mem ?a - imm*) che rappresenta il valore attuale della locazione di memoria *?a*

Vengono create tante costanti quante i registri. Attualmente si è proceduto a modellare solo gadget per l'impostazione di registri o la scrittura di memoria. È da notare che per lo stratagemma usato tutti i valori (indirizzi e valori concreti) che le nostre azioni vanno ad utilizzare devono essere esplicitati. Un gadget per l'impostazione di un registro viene tradotto in questo modo (a meno dei puntini utilizzati per generalizzare la lista dei registri che è possibile impostare attraverso il gadget):

```

1  (:action regset_gadget
2    :parameters (?vreg0 ?vreg1 ... ?vregn - imm)
3    :precondition (and)
4    :effect (and
5      (assign (reg reg0) (val ?vreg0))
6      (assign (reg reg1) (val ?vreg1))
7      ...
8      (assign (reg regn) (val ?vregn))
9      (increase (stack-length) g.stack_offset)))
```

Come si può notare la traduzione avviene ad un livello d'astrazione più alto delle singole istruzioni del gadget, dettagli come la posizione dei valori da impostare nello stack, gli effetti secondari, vengono gestiti sempre da dropper. La traduzione invece di un gadget per la scrittura in memoria è leggermente più complicata:

```

1 (:action memstr_gadget
2   :parameters ()
3   :precondition (and)
4   :effect (and
5             (forall (?a -imm)
6               (when (= (val ?a) (reg rdi))
7                 (assign (mem ?a) (reg rsi))))
8             (increase (stack-length) 0)))

```

Questa modellazione poco elegante è dovuta al non poter utilizzare i fluents come argomenti per altri fluents. Una volta tradotto il dominio, si crea un'istanza del problema. Si specificano gli oggetti che faranno parte dell'istanza del problema, cioè i valori che andremo ad utilizzare. Come stato iniziale si impostano i fluents dei registri a zero, si assegnano i rispettivi valori ai fluents di tipo (val ?v - imm) e si setta anche il fluent stack-length a zero, quest'ultimo viene utilizzato come metrica per valutare la bontà del piano trovato. Come stato desiderato si imposta 0, nel caso si voglia trovare un piano per settare un insieme di registri, che i fluent rilevanti di tipo (reg ?r) abbiano i valori desiderati 0, nel caso invece si voglia trovare un piano per impostare alcune specifiche locazioni di memoria, che i fluents del tipo (mem ?a) abbiano il valore corrispondente. Un esempio, con la lista dei gadgets accorciata per brevità è riportato nelle figure 4.4 e 4.4. L'esempio è generato tramite la classe planner.

```

1
2 ;gadgets:
3 ;0x412050 : pop rsi; pop r15; ret
4 ;0x412052 : pop rdi; ret
5 ;0x40ea2c : mov dword ptr [rdi], esi; ret
6
7 (define (domain dropper )
8   (:requirements :typing :fluents :conditional-effects)
9   (:types imm register)

```

```

10 (:constants rax rbx rcx rdx rdi rsi rbp rsp rip r8 r9
    r10 r11 r12 r13 r14 r15 - register)
11
12 (:functions
13   (val ?x -imm)
14   (reg ?r - register)
15   (stack-length)
16   (mem ?addres - imm))
17
18 (:action regset_412052
19   :parameters (?vrdi - imm)
20   :precondition (and)
21   :effect (and (assign (reg rdi) (val ?vrdi))
22               (increase (stack-length) 8)))
23
24 (:action regset_412050
25   :parameters (?vr15 ?vr15i - imm)
26   :precondition (and)
27   :effect (and (assign (reg r15) (val ?vr15))
28               (assign (reg rsi) (val ?vr15i))
29               (increase (stack-length) 16)))
30
31 (:action memstr_40ea2c
32   :parameters ()
33   :precondition (and)
34   :effect (and (forall (?a ?v -imm)
35                   (when (and (= (val ?a) (reg rdi))
36                           (= (val ?v) (reg rsi)))) (assign (mem ?a) (val ?v)
37                                                           )))
38   (increase (stack-length) 0)))
39 )

1 (define (problem memset)
2   (:domain dropper)
3   (:objects v_32896 v_2 v_33153 v_3 - imm)
4   (:init
5     (= (val v_32896) 32896)

```



```
6 (= (val v_33153) 33153)
7 (= (val v_2) 2)
8 (= (val v_3) 3)
9 (= (reg rax) 0)(= (reg rbx) 0)(= (reg rcx) 0)(= (reg
    rdx) 0)(= (reg rdi) 0)
10 (= (reg rsi) 0)(= (reg rbp) 0)(= (reg rsp) 0)(= (reg
    rip) 0)(= (reg r8) 0)
11 (= (reg r9) 0)(= (reg r10) 0)(= (reg r11) 0)(= (reg r12
    ) 0)(= (reg r13) 0)
12 (= (reg r14) 0)(= (reg r15) 0)
13 (= (mem v_32896) 0)
14 (= (mem v_33153) 0)
15 (= (stack-length) 0))
16 (:goal
17 (and (= (mem v_32896) 2)
18      (= (mem v_33153) 3)))
19 (:metric minimize (stack-length))
20 )
```

Capitolo 5

Conclusioni

Lo sviluppo di uno strumento come dropper mi ha permesso di studiare ed esplorare problematiche interessanti e complesse. Uno strumento che riesce infatti ad analizzare un file binario e da esso estrarne in maniera automatica le informazioni necessarie per poter costruire un payload funzionante implica la risoluzione di diverse problematiche che abbracciano più aree dell'informatica. In particolare in questo lavoro alcuni strumenti propri dell'intelligenza artificiale hanno giocato un ruolo cruciale rendendo evidente l'apporto che questa disciplina può dare all'area della sicurezza informatica in generale. Tra le problematiche più rilevanti nello sviluppo di uno strumento come dropper elenchiamo:

1. L'estrapolazione della semantica dei singoli gadget
2. L'individuazione di una sequenza di gadget che ci consente di eseguire un'operazione articolata. Questo punto è complicato dal fatto che gli effetti di un gadget possono interferire con quelli di un altro nonché con l'esecuzione stessa del programma in esame
3. Scegliere, in base alle operazioni disponibili, la strategia da utilizzare per eseguire l'exploit
4. Individuare una sequenza di operazioni che portino a successo una data strategia

Il primo punto è stato affrontato, come descritto nei capitoli 3 e 4, attraverso sia tecniche di emulazione che tecniche di verifica basate sulla rappresentazione in formule logiche delle istruzioni dei gadget. Dropper attualmente può estrapolare la semantica di tipologie che ci permettono di:

- Impostare i valori di registri
- Effettuare operazioni aritmetiche in locazioni di memoria
- Scrivere su locazioni di memoria
- Azzerare il carry flag

Vengono inoltre inferite le informazioni necessarie per l'utilizzo dei gadget e gli effetti secondari con altri gadget (clobbering dei registri, scritture in aree di memoria).

La scelta di una sequenza di gadget che ci permetta di eseguire un'operazione articolata è un'altra problematica interessante. Infatti, oltre ad essere sicuri che la catena abbia gli effetti desiderati, è interessante cercare, tra le sequenze di gadget che ci permettano una particolare operazione, quella che produca un payload di minore lunghezza. Le catene che attualmente dropper riesce a generare combinano le tipologie di gadget viste sopra e ci consentono una visione ad un livello di astrazione più alto delle operazioni che possiamo eseguire con i gadget disponibili. Per generare le catene di queste operazioni, come descritto nei capitoli precedenti, si utilizza un approccio per lo più programmatico, usando quando possibile algoritmi greedy per la generazione di soluzioni di una certa qualità, cioè il cui payload abbia una lunghezza contenuta. Tuttavia il problema di generazione di una catena, definito come l'ordine nel quale effettuare alcune azioni (i gadget) per raggiungere un dato stato del sistema, si presta naturalmente ad una traduzione in un problema di planning. È stata esplorata questa strada, traducendo il problema, una volta estratta la semantica dei gadget, nel linguaggio PDDL 2.1 [2, 9]. La strategia di modellizzazione utilizzata in questo primo approccio è riportata in 4.4. Le ultime problematiche da affrontare, nella nostra panoramica dal basso verso l'alto, sono la scelta di una tecnica di exploiting e trovare una sequenza di operazioni per applicare tale tecniche. Attualmente sono implementate le seguenti strategie:

- utilizzo della funzione “read” per la scrittura in memoria
- utilizzo di sequenza di gadget per scritture dai in memoria
- got patching
- return-to-plt

Trovare questa sequenza è un problema per certi versi simile a trovare le catene di gadget per eseguire le operazioni “elementari”, ma da un punto di astrazione più alto. Vi è quindi, tra le difficoltà più rilevanti, quella di esaminare tutte le possibili sequenze di operazioni per applicare quella tecnica. In questa fase i vantaggi, soprattutto pensando a tecniche non ancora implementate come *got dereferencing*, dell'utilizzo di un planner sembrano ancora più rilevanti. Lo strumento è stato testato su alcuni livelli di exploit-exercise[1] e su alcune delle bin-utils (ls, echo, mv), riuscendo a ritornare payload funzionanti una volta iniettati nello stack.

5.1 Sviluppi futuri

Dropper ha prospettive di sviluppo su diversi fronti.

L'aggiunta dell'estrapolazione semantica per le categorie di gadget mancanti consentirebbe l'applicazione di ulteriori tecniche per l'exploitation.

Per quanto riguarda la generazione della catena invece si è iniziato ad utilizzare un planner, ma essendo ancora ad una fase iniziale vi è molto spazio per ulteriori sviluppi e indagini.

Un'altra idea interessante è cercare di estrapolare non solo gadget “classici” ma anche altre tipologie, come ad esempio gadget che termino con un jmp invece che con un ret, utilizzati nella *Jump Oriented Programming*, oppure gadget di lunghezza maggiore ma con effetti secondari “controllabili” (ad esempio gadget lunghi ma dove si può forzare un flusso di esecuzione). Quest'ultima tipologia di gadget è necessaria per eludere alcune tecniche di mitigazione che si basano sul monitoraggio di un numero limitato di istruzioni.

Un vantaggio notevole, si avrebbe nell'effettuare anche simulazioni simboliche per l'estrapolazione e la verifica semantica dei gadget.

Bibliografia

- [1]
- [2] Pddl - the planning domain definition language, 1997.
- [3] Clark Barrett and Cesare Tinelli. Satisfiability modulo theories. In Edmund Clarke, Tom Henzinger, and Helmut Veith, editors, *Handbook of Model Checking*. Springer, 2014.
- [4] Eli Bendersky. pyelftools, 2014.
- [5] c0ntex. Bypassing non-executable-stack during exploitation using return-to-libc, 96.
- [6] Lucas Davi, Ahmad-Reza Sadeghi, Daniel Lehmann, and Fabian Monrose. Stitching the gadgets: On the ineffectiveness of coarse-grained control-flow integrity protection. In *23rd USENIX Security Symposium (USENIX Security 14)*, pages 401–416, San Diego, CA, August 2014. USENIX Association.
- [7] Solar Designer.
- [8] Solar Designer. return-to-libc, August 1997.
- [9] Maria Fox and Derek Long. Pddl2.1: An extension to pddl for expressing temporal planning domains. *Journal of Artificial Intelligence Research*, 20:2003, 2003.
- [10] Christian Heitman and Iván Arce. Barf: A multiplatform open source binary analysis and reverse engineering framework, 2014.
- [11] ELF Kickers, 1997.
- [12] Aleph One. Smashing the stack for fun and profit. *phrack*, 96.

- [13] Ryan Roemer, Erik Buchanan, Hovav Shacham, and Stefan Savage. Return-oriented programming: Systems, languages, and applications. *ACM Trans. Inf. Syst. Secur.*, 15(1):2:1–2:34, March 2012.
- [14] Ryan Roemer, Erik Buchanan, Hovav Shacham, and Stefan Savage. Return-oriented programming: Systems, languages, and applications. *ACM Trans. Info. & System Security*, 15(1), March 2012.
- [15] Giampaolo Fresi Roglia, Lorenzo Martignoni, Roberto Paleari, and Danilo Bruschi. Surgically returning to randomized lib (c). In *Computer Security Applications Conference, 2009. ACSAC'09. Annual*, pages 60–69. IEEE, 2009.
- [16] Edward J. Schwartz, Thanassis Avgerinos, and David Brumley. Q: Exploit hardening made easy. In *Proceedings of the USENIX Security Symposium*, 2011.
- [17] Hovav Shacham. The geometry of innocent flesh on the bone: Return-into-libc without function calls (on the x86). In *Proceedings of the 14th ACM Conference on Computer and Communications Security*, CCS '07, pages 552–561, New York, NY, USA, 2007. ACM.
- [18] Hovav Shacham, Matthew Page, Ben Pfaff, Eu-Jin Goh, Nagendra Modadugu, and Dan Boneh. On the effectiveness of address-space randomization. In *Proceedings of the 11th ACM Conference on Computer and Communications Security*, CCS '04, pages 298–307, New York, NY, USA, 2004. ACM.